

Laporan Analisis Ujian Tengah Semester Machine Learning

Oleh:

Aryo Adi Putro

NIM: 2341720084



PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNOLOGI INFORMASI

POLITEKNIK NEGERI MALANG

2025

Laporan Analisis Dataset (ringkasan)

1) Penjelasan singkat dataset

- Jumlah sampel (total): **1460**

- Jumlah kolom: **81**
- Contoh fitur teratas digunakan untuk clustering (dipilih berdasarkan varians, 12 fitur): sum_SalePrice_LotArea, SalePrice, LotArea, MiscVal, GrLivArea, BsmtFinSF1, BsmtUnfSF, 2ndFlrSF, 1stFlrSF, TotalBsmtSF (selengkapnya ada di file ringkasan JSON).

2) Proses preprocessing

- Menghapus duplikasi jika ada.
- Imputasi nilai hilang: **numerik -> median, kategori -> modus**.
- Encoding: one-hot untuk kategori dengan kardinalitas kecil (≤ 6).
- Pembuatan fitur baru: sum_SalePrice_LotArea (jumlah dari dua fitur numerik bervarians tertinggi).
- Normalisasi: StandardScaler pada fitur numerik terpilih sebelum clustering.

3) Hasil clustering

KMeans


- Rentang k diuji: 2–5.
- **K terbaik (Silhouette): $k = 3$** (Silhouette ≈ 0.1383)

DBSCAN


- Kandidat eps diuji dari beberapa persentil k-distance.
- **EPS terbaik:** 1.5 (Silhouette ≈ -0.1939)

Visualisasi 2D (PCA)

- Fokus subset fitur numerik



- Tidak fokus subset fitur numerik



4) Implementasi Annoy

- Menggunakan `sklearn.NearestNeighbors` untuk menemukan tetangga terdekat.
- Memilih **5 titik query acak** dari sampel. Untuk tiap query dilaporkan indeks tetangga terdekat dan jarak.

5) Hasil pemeriksaan tetangga (Apakah tetangga berada dalam cluster yang sama?)

- Ya, hasil pemeriksaan menunjukkan tetangga berada dalam cluster yang sama. Namun untuk poin fokus subset fitur numerik, terdapat satu tetangga yang tidak berada dalam cluster yang sama.
 - Tidak fokus subset fitur numerik

Query Point Index: 962
Cluster (KMeans): 1
Tetangga Terdekat & Jaraknya:
- Neighbor Index: 962 Distance: 0.0000 Cluster (KMeans): 1
- Neighbor Index: 590 Distance: 4.9006 Cluster (KMeans): 1
- Neighbor Index: 1106 Distance: 7.5617 Cluster (KMeans): 1
- Neighbor Index: 717 Distance: 7.8488 Cluster (KMeans): 1
- Neighbor Index: 989 Distance: 7.9485 Cluster (KMeans): 1
Query Point Index: 369
Cluster (KMeans): 1
Tetangga Terdekat & Jaraknya:
- Neighbor Index: 369 Distance: 0.0000 Cluster (KMeans): 1
- Neighbor Index: 590 Distance: 7.9856 Cluster (KMeans): 1
- Neighbor Index: 1106 Distance: 8.0864 Cluster (KMeans): 1
- Neighbor Index: 962 Distance: 8.2716 Cluster (KMeans): 1
- Neighbor Index: 717 Distance: 8.8849 Cluster (KMeans): 1
Query Point Index: 706
Cluster (KMeans): 0
Tetangga Terdekat & Jaraknya:
- Neighbor Index: 706 Distance: 0.0000 Cluster (KMeans): 0
- Neighbor Index: 1115 Distance: 11.6623 Cluster (KMeans): 0
- Neighbor Index: 141 Distance: 11.7492 Cluster (KMeans): 0
- Neighbor Index: 1068 Distance: 14.7642 Cluster (KMeans): 0
- Neighbor Index: 921 Distance: 16.1409 Cluster (KMeans): 0
Query Point Index: 1195
Cluster (KMeans): 1
Tetangga Terdekat & Jaraknya:
- Neighbor Index: 1195 Distance: 0.0000 Cluster (KMeans): 1
- Neighbor Index: 708 Distance: 2.2957 Cluster (KMeans): 1
- Neighbor Index: 1344 Distance: 2.6412 Cluster (KMeans): 1
- Neighbor Index: 857 Distance: 3.1741 Cluster (KMeans): 1
- Neighbor Index: 119 Distance: 3.5022 Cluster (KMeans): 1

```

Query Point Index: 202
Cluster (KMeans): 1
Tetangga Terdekat & Jaraknya:
- Neighbor Index: 202 | Distance: 0.0000 | Cluster (KMeans): 1
- Neighbor Index: 373 | Distance: 5.7568 | Cluster (KMeans): 1
- Neighbor Index: 1214 | Distance: 6.3227 | Cluster (KMeans): 1
- Neighbor Index: 1104 | Distance: 8.1153 | Cluster (KMeans): 1
- Neighbor Index: 225 | Distance: 8.1628 | Cluster (KMeans): 1

```

- o Fokus subset fitur numerik

Query Index: 1050	Cluster (KMeans): 1
Tetangga terdekat:	
- Neighbor: 1050	Distance: 0.0000 Cluster (KMeans): 1
- Neighbor: 415	Distance: 0.8493 Cluster (KMeans): 1
- Neighbor: 401	Distance: 1.8465 Cluster (KMeans): 1
- Neighbor: 742	Distance: 2.0888 Cluster (KMeans): 1
- Neighbor: 388	Distance: 2.1078 Cluster (KMeans): 1
Query Index: 1214	Cluster (KMeans): 2
Tetangga terdekat:	
- Neighbor: 1214	Distance: 0.0000 Cluster (KMeans): 2
- Neighbor: 97	Distance: 2.4586 Cluster (KMeans): 2
- Neighbor: 609	Distance: 2.7466 Cluster (KMeans): 2
- Neighbor: 10	Distance: 3.0438 Cluster (KMeans): 2
- Neighbor: 951	Distance: 3.1183 Cluster (KMeans): 2
Query Index: 440	Cluster (KMeans): 1
Tetangga terdekat:	
- Neighbor: 440	Distance: 0.0000 Cluster (KMeans): 1
- Neighbor: 332	Distance: 6.2949 Cluster (KMeans): 1
- Neighbor: 898	Distance: 6.5775 Cluster (KMeans): 1
- Neighbor: 515	Distance: 6.8718 Cluster (KMeans): 1
- Neighbor: 987	Distance: 7.1200 Cluster (KMeans): 1
Query Index: 583	Cluster (KMeans): 1
Tetangga terdekat:	
- Neighbor: 583	Distance: 0.0000 Cluster (KMeans): 1
- Neighbor: 875	Distance: 6.7794 Cluster (KMeans): 1
- Neighbor: 621	Distance: 7.2044 Cluster (KMeans): 1
- Neighbor: 293	Distance: 7.7975 Cluster (KMeans): 1
- Neighbor: 988	Distance: 7.8953 Cluster (KMeans): 0
Query Index: 552	Cluster (KMeans): 1
Tetangga terdekat:	
- Neighbor: 552	Distance: 0.0000 Cluster (KMeans): 1
- Neighbor: 1451	Distance: 1.8176 Cluster (KMeans): 1
- Neighbor: 1002	Distance: 1.9421 Cluster (KMeans): 1
- Neighbor: 13	Distance: 2.1099 Cluster (KMeans): 1
- Neighbor: 468	Distance: 2.2614 Cluster (KMeans): 1

Kesimpulan singkat

a. Perbedaan hasil KMeans dan DBSCAN, mana yang lebih baik?

KMeans ($k=3$) menunjukkan nilai Silhouette lebih tinggi dibanding DBSCAN pada eps terbaik, sehingga KMeans memberikan pemisahan cluster global yang lebih baik pada fitur yang dipilih. DBSCAN lebih sensitif pada parameter eps dan cocok jika cluster berbentuk non-linier; pada sample ini DBSCAN menghasilkan lebih sedikit/lebih kecil cluster sehingga metrik lebih rendah.

- Hasil Tidak fokus subset fitur numerik dan fokus subset fitur numerik

```
KMeans Silhouette Score: 0.1383
KMeans Davies-Bouldin Index: 2.4972
DBSCAN Silhouette Score: -0.1939
DBSCAN Davies-Bouldin Index: 1.9043
```

```
KMeans → Silhouette Score: 0.1366 | Davies-Bouldin Index: 2.5064
DBSCAN → Silhouette Score: -0.1939 | Davies-Bouldin Index: 1.9043
```

b. Nilai metrik terbaik:

- Silhouette terbaik: **0.1366** (KMeans, $k=3$).

c. Hasil query “Annoy” (NearestNeighbors): apakah tetangga yang ditemukan termasuk dalam cluster yang sama?

- Pada sample ini, sebagian besar tetangga terdekat berada dalam cluster KMeans yang sama dengan query point — ini menunjukkan konsistensi lokal di ruang fitur yang dinormalisasi. Untuk DBSCAN, bila point bukan noise dan cluster cukup besar, tetangga juga sering berada di cluster yang sama.